

附录B 线性代数中的定义和基本概念

这是对线性代数和矩阵代数基础的一个概要，MATLAB中也包含了用到的所有概念。

B.1 向量

线性空间由可以进行加和数乘运算的向量组成。

线性空间 R^n 由列向量组成：

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

其中，元素 x_k 和 y_k 为实数，长度为 n 。

在线性空间 C^n 中，元素可以为复数。

加法的定义是各元素分别相加：

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{pmatrix}$$

数乘定义为各元素分别与数相乘：

$$\alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_n \end{pmatrix}$$

所有元素均为零的向量定义为零向量。

$$\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

在线性空间的 p 个向量中，即 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ 的集合，如果至少有一个向量可以由其他向量线性表示，则称这 p 个向量是线性相关的。

$$\mathbf{x}_p = \alpha_1 \mathbf{x}_1 + \dots + \alpha_{p-1} \mathbf{x}_{p-1}$$

这里 α_i 为标量。

如果不能这样表示，则称这些向量线性无关。线性无关最通常的定义是： $\alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_p \mathbf{x}_p = \mathbf{0}$ 成立，当且仅当 $\alpha_1 = \alpha_2 = \dots = \alpha_p = 0$ 。

例B.1

向量

$$\mathbf{x}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad \mathbf{x}_2 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} \quad \mathbf{x}_3 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

在线性空间 R^n 中是线性无关的。

线性空间中线性无关向量的最大个数称为线性空间的维数。 R^n 和 C^n 的维数均为 n 。注意：在有些情况下认为 C^n 是 $2n$ 维的更为方便，这样就能分成实部和虚部两部分。

线性空间的基指的是一些向量的集合，这个空间中所有的向量都能由这些向量线性表示。基中向量的个数等于空间的维数。线性空间中有无穷多组基。

例B.2


在例B.1中的向量形成 R^3 和 C^3 空间中的基。向量：

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad \mathbf{e}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

形成同样空间中更常用的基，有：

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + x_3 \mathbf{e}_3$$

这是 R^3 空间中一个由基向量线性表示的任意向量。可用图 B-1 来表示说明。



图B-1 向量和它的分量

C^n 中两个向量 \mathbf{x} 和 \mathbf{y} 的内积或点积，通常写作 (\mathbf{x}, \mathbf{y}) 或 $\langle \mathbf{x}, \mathbf{y} \rangle$ ，定义为：

$$(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n \bar{x}_i y_i$$

如果严格限在 R^n 空间中，则 x_i 的复数共轭将是不必要的。可以使用下一节将要介绍的符号， $(\mathbf{x}, \mathbf{y}) = \mathbf{x}^H \mathbf{y}$ 。

C^n 中向量的欧几里德范数 $\|\mathbf{x}\|_2$ 定义为：

$$\|\mathbf{x}\|_2^2 = (\mathbf{x}, \mathbf{x}) = \sum_{i=1}^n |x_i|^2 = \mathbf{x}^H \mathbf{x}$$

范数用来度量向量的大小或长度。还有许多其他范数，将在 B.6 节中介绍其中的一些范数。

如果 $(\mathbf{x}, \mathbf{y}) = 0$ ，则称两个向量 \mathbf{x} 和 \mathbf{y} 正交。

两个向量 \mathbf{x} 和 \mathbf{y} 之间的角度 θ 是按下式来定义的：

$$\cos \theta = \frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{x}\|_2 \|\mathbf{y}\|_2}$$

已经知道两个正交向量之间的夹角是 $\pi/2$ 或 90 度，即两个向量是垂直的。零向量与任何向量都正交。

如果非零向量集合 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ 中所有向量都正交，则它们构成正交系，其中的向量也是线性无关的。因此，正交化比线性无关的条件更强。如果 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p$ 形成一个正交系，并且每个向量的欧氏范数均为 1，则称为标准正交系。标准正交系中的向量有如下关系：

$$(\mathbf{x}_j, \mathbf{x}_k) = \begin{cases} 0 & j \neq k \\ 1 & j = k \end{cases}$$

例B.3

例B.2中的向量 $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$ 构成 R^3 (和 C^3) 中的标准正交系。在标准的笛卡儿坐标系中，它们分别代表 x, y, z 轴。

除了以列向量的形式定义外，还可以以行向量的形式定义上述所有概念。

$$\mathbf{v} = (v_1, v_2, \dots, v_p)$$

但是，使用列向量有几个优点。

B.2 矩阵介绍

矩阵是一个以行列形式排列的数字矩形数组。一个有 m 行 n 列的矩阵称为 $m \times n$ 矩阵。例如，这里有一个 2×3 矩阵：

$$\begin{pmatrix} 2 & 1 & 3 \\ 3 & -2 & 0 \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \end{pmatrix}$$

矩阵中的数字称为矩阵的元素或分量。如果矩阵命名为 \mathbf{A} ，矩阵 \mathbf{A} 的元素称为 a_{ij} ，这里 i 代表行下标， j 代表列下标，即 a_{ij} 代表 i 行 j 列的元素。

$n \times n$ 矩阵称为方阵。

矩阵的大小由行数 m 和列数 n 给出。对于方阵来说， n 有时也指矩阵的阶数。

矩阵中从左上角到右下角的对角线称为主对角线，主对角线上的元素称为对角元素 a_{ii} 。从右上角到左下角的对角线称为反对角线。主对角线上方和下方的对角线分别称为上对角线 and 下对角线。

大小相同的两个矩阵相加定义为矩阵的各个元素分别相加。矩阵 $\mathbf{C} = \mathbf{A} + \mathbf{B}$ ，也就是元素 $c_{ij} = a_{ij} + b_{ij}$ 。

数乘的定义也是每个元素分别相乘。矩阵 \mathbf{A} 的元素为 a_{ij} 。

矩阵乘法仅在左侧矩阵的列数等于右侧矩阵的行数时才有意义。矩阵 $\mathbf{C} = \mathbf{AB}$ 是一个 $m \times n$ 矩阵，这里 \mathbf{A} 为 $m \times p$ 矩阵， \mathbf{B} 为 $p \times n$ 矩阵。

$$c_{ij} = \sum_{k=1}^p a_{ik} b_{kj}$$

元素 c_{ij} 为 \mathbf{A} 中 i 行和 \mathbf{B} 中 j 列的内积。

即使 \mathbf{AB} 有意义，但 \mathbf{BA} 不一定有意义。如果 \mathbf{A} 和 \mathbf{B} 都是 n 阶方阵，那么 \mathbf{AB} 和 \mathbf{BA} 将都有意义，但是通常 $\mathbf{AB} \neq \mathbf{BA}$ 。矩阵乘法是不可交换的。

n 阶单位矩阵是一个 $n \times n$ 矩阵，其中除对角线上元素为 1 外，其余元素均为 0，用 \mathbf{I} 或 \mathbf{I}_n 表示。 \mathbf{A} 矩阵乘单位矩阵，结果不变，因此有 $\mathbf{IA} = \mathbf{A}$ 和 $\mathbf{AI} = \mathbf{A}$ 。

列向量可看成是 $n \times 1$ 矩阵，而行向量可看成是 $1 \times n$ 矩阵。有时将一个标量看成 1×1 矩阵也是十分有用的。

如果 \mathbf{x} 是一个有 n 个分量的列向量，而 \mathbf{A} 是一个 $n \times n$ 阶矩阵，那么 \mathbf{Ax} 也是有 n 个分量的列向量。这称为矩阵—向量乘法。

转置是将矩阵的行和列交换位置，转置运算符记做 T 。如果 \mathbf{A} 是一个元素为 a_{ij} 的 $m \times n$ 矩阵，那么转置矩阵 \mathbf{A}^T 是一个元素为 a_{ji} 的 $n \times m$ 矩阵。转置也可以看成是这样： \mathbf{A} 的第 1 列作为转置矩阵中的第 1 行， \mathbf{A} 的第 2 列作为转置矩阵中的第 2 行，依次类推。

矩阵的共轭是一个矩阵，其中的元素是原矩阵中复数元素的共轭。结果记做 $\bar{\mathbf{A}}$ 。一个常用的操作符是共轭转置，这将形成矩阵 $\bar{\mathbf{A}}^T$ 或等价的 $\overline{\mathbf{A}^T}$ 。该矩阵通常记做 \mathbf{A}^H ， \mathbf{A}^* ，在 MATLAB 中记做 \mathbf{A}' 。

两个列向量 \mathbf{x} 和 \mathbf{y} 的内积常写成：

$$(\mathbf{x}, \mathbf{y}) = \sum_{i=1}^n \bar{x}_i y_i = \mathbf{x}^H \mathbf{y}$$

欧氏范数可写成 $\|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^H \mathbf{x}}$ 。注意： $\mathbf{x}^H \mathbf{x}$ 是一个标量，因为它是 $1 \times n$ 阶矩阵和 $n \times 1$ 阶矩阵的内积。相反， $\mathbf{x} \mathbf{y}^H$ 是一个 $n \times n$ 阶矩阵。

B.3 矩阵概念

矩阵不只是一个数字的集合。一些重要而有用的数学概念都与矩阵有关。

矩阵 \mathbf{A} 的秩， $\text{rank}(\mathbf{A})$ 是矩阵 \mathbf{A} 中线性无关列的列数，并且总是等于矩阵 \mathbf{A} 中线性无关行的行数。如果 \mathbf{A} 为 $m \times n$ 矩阵，则秩小于或等于 $\min(m, n)$ 。

方阵 \mathbf{A} 的行列式， $\det(\mathbf{A})$ ，是一个可以用不同方式定义和计算的标量。有下列结论：

- 1) $\det(\mathbf{A}) = \det(\mathbf{A}^T)$ 。
- 2) $\det(\mathbf{A}^H) = \overline{\det(\mathbf{A})}$ 。
- 3) 如果 \mathbf{A} 中有两行相等，或某一行可由其他行线性表示，则 $\det(\mathbf{A})=0$ 。对于 \mathbf{A} 的列也有同样的结论。
- 4) 某行减去另一行与一个标量的乘积，行列式不变。对于列也有同样的结论。
- 5) 交换任意两行，行列式变号。对于列也有同样的结论。
- 6) 主对角线下方所有元素均为零的矩阵称为上三角矩阵，其行列式为主对角元素的乘积。对于下三角矩阵也有同样的结论。

7) 矩阵乘积的行列式等于行列式的乘积。这是一个重要的乘法定理： $\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B})$ 。

8) 矩阵行列式的计算可用高斯消元法来很好地求得。

n 阶线性方程组可以记成如下明确的形式：

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = b_n \end{cases}$$

或用 $\mathbf{A}=(a_{ij})$ ， $\mathbf{x}=(x_1, x_2, \dots, x_n)^T$ 和 $\mathbf{b}=(b_1, b_2, \dots, b_n)^T$ 来表示：

$$\mathbf{Ax}=\mathbf{b}$$

将向量 a_1, a_2, \dots, a_n 看作 \mathbf{A} 的列, 该方程组可被写成如下的半压缩形式。

$$x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \dots + x_n \mathbf{a}_n = \mathbf{b}$$

当且仅当 $\det(\mathbf{A}) \neq 0$ 时方程组有唯一解。

$m \times n$ 阶矩阵 \mathbf{A} 的值域 $\mathcal{R}(\mathbf{A})$ 是 \mathbf{A} 的列 a_1, a_2, \dots, a_n 的所有线性的组合。这是一个线性空间, 并且 $\mathcal{R}(\mathbf{A})$ 的维数等于 $\text{rank}(\mathbf{A})$ 。

矩阵 \mathbf{A} 的零空间 $\mathcal{N}(\mathbf{A})$ 是所有使得 $\mathbf{Ax}=\mathbf{0}$ 的向量集合, 即齐次方程组的解。这也是一个线性空间, 并且维数等于 $m - \text{rank}(\mathbf{A})$ 。

\mathbf{A}^T 的值域和零空间的定义同上。

方程系 $\mathbf{AX}=\mathbf{I}$ 是一个矩阵方程, 其中 \mathbf{A} 是一个 $n \times n$ 矩阵, 而 \mathbf{I} 为 n 阶单位阵。使用符号 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 和 $\mathbf{e}_1=(1, 0, \dots, 0)^T, \mathbf{e}_2=(0, 1, \dots, 0)^T, \dots, \mathbf{e}_n=(0, 0, \dots, 1)^T$ 作为 \mathbf{X} 和 \mathbf{I} 的列, 根据:

$$\mathbf{X} = (\mathbf{x}_1 \quad \mathbf{x}_2 \quad \dots \quad \mathbf{x}_n) \quad \mathbf{I} = (\mathbf{e}_1 \quad \mathbf{e}_2 \quad \dots \quad \mathbf{e}_n)$$

可以将矩阵方程写成线性方程组的集合:

$$\mathbf{Ax}_k = \mathbf{e}_k \quad k = 1, 2, \dots, n$$

当且仅当 $\det(\mathbf{A}) \neq 0$ 时方程组有唯一的解。 $\mathbf{AX}=\mathbf{I}$ 的解 \mathbf{X} 被称为 \mathbf{A} 的逆, 记为 \mathbf{A}^{-1} ,

有 $\mathbf{A} \mathbf{A}^{-1}=\mathbf{I}$ 和 $\mathbf{A}^{-1} \mathbf{A}=\mathbf{I}$ 。

逆的计算通常也使用高斯消元法。存在逆的矩阵称为非奇异矩阵, 否则称为奇异矩阵。

方阵的特征值和特征向量可用如下的方程定义:

$$\mathbf{Ax}=\lambda \mathbf{x}$$

这等价于齐次方程组:

$$(\mathbf{A} - \lambda \mathbf{I})\mathbf{x}=\mathbf{0}$$

对于每个矩阵 \mathbf{A} 和 λ , 向量 $\mathbf{x}=\mathbf{0}$ 都是一个解。但是, 如果 $\det(\mathbf{A} - \lambda \mathbf{I}) \neq 0$, 则方程组还有非零解。这些 $\mathbf{x}_k \neq \mathbf{0}$ 的解称为 \mathbf{A} 的特征向量, 相应的 λ_k 称为特征值或特征根。在复平面上 \mathbf{A} 总有 n 个特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 。特征值和它相应的特征向量称为特征对。

函数 $\phi(\lambda)=\det(\mathbf{A}-\lambda \mathbf{I})$ 是 λ 的 n 次多项式, 也称为 \mathbf{A} 的特征多项式。特征方程为 $\phi(\lambda)=0$ 。

总有这样的结论: 矩阵多项式 $\phi(\mathbf{A})=\mathbf{0}$, 这就是 Cayley-Hamilton 定理。

如果 \mathbf{C} 为非奇异矩阵, \mathbf{A} 和 \mathbf{B} 定义成 $\mathbf{B}=\mathbf{C}^{-1} \mathbf{A} \mathbf{C}$, 则称 \mathbf{A} 和 \mathbf{B} 为相似矩阵, \mathbf{A} 和 \mathbf{B} 之间的变换称为相似变换。相似变换不改变矩阵的特征值。

矩阵 \mathbf{A} 的谱半径 $\rho(\mathbf{A})$ 定义为 $\max_i |\lambda_i|$ 。

如果矩阵 \mathbf{A} 、 \mathbf{B} 的逆存在, 则对逆、转置和共轭转置如下的式子成立:

$$(\mathbf{AB})^{-1} = \mathbf{B}^{-1} \mathbf{A}^{-1} \quad \text{如果所有的逆都存在}$$

$$(\mathbf{AB})^T = \mathbf{B}^T \mathbf{A}^T$$

$$(\mathbf{AB})^H = \mathbf{B}^H \mathbf{A}^H$$

下面的等价链包含了上述的大部分定义。 \mathbf{A} 为 n 阶方阵。

线性方程 $\mathbf{Ax}=\mathbf{b}$ 有唯一的解

$$\det(\mathbf{A}) \neq 0$$

A^{-1} 存在 A 的秩为 n A 的列线性无关 A 的行线性无关 A 的值域维数为 n A 的零空间维数为0齐次方程组 $Ax=0$ 有唯一的零解 $\lambda=0$ 不是 A 的特征值

B.4 矩阵分类

矩阵可用多种方式分类。一个矩阵中如果所有非对角元素均为零，则称为对角阵。如果所有主对角线下方的元素均为0，则称为上三角阵，如果对角线上的元素也都为零，则称为严格上三角阵。同样，也可以定义下三角阵和严格下三角阵。

如果仅在主对角线、第一条上对角线和第一条下对角线上有非零元素，则称矩阵为三对角矩阵。更一般的是，如果所有非零元素均在主对角线周围的带形区域内，则称为带状矩阵。

如果第一条子对角线下方的元素均为零，则称为上海森伯格形式。

如果矩阵中大部分元素都是零，称为稀疏矩阵；否则，称为满矩阵。带状矩阵属于稀疏矩阵。使用分块矩阵也是十分有用的，分块矩阵即矩阵的元素也是矩阵。实际上代数运算不变。

假设 A, B 的定义如下：

$$A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix} \quad B = \begin{pmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{pmatrix}$$

可给出 $C=AB$ ：

$$C = \begin{pmatrix} C_{11} & C_{12} \\ C_{21} & C_{22} \end{pmatrix}$$

其中，比如： $C_{11} = A_{11}B_{11} + A_{12}B_{21}$ 。

块矩阵有时也称为分区矩阵。在前面的例子中，子矩阵的大小必须一致。类似块对角阵，块上三角阵的定义就不再赘述了。

矩阵还可以按数学性质分类。已介绍过的一些概念，这里再重复一下。

如果 $\det(A) \neq 0$ ，则称矩阵 A 为非奇异矩阵，这意味着所有的特征值都是非零值。如果

$\det(\mathbf{A})=0$ ，矩阵为奇异矩阵，至少有一个特征值为零。

如果 $\mathbf{A}^H = \mathbf{A}$ ，矩阵 \mathbf{A} 为 Hermitian 矩阵。这与实数阵的对称矩阵类似。特征值为实数，特征向量形成一个标准正交基。

如果 $\mathbf{A}^H = -\mathbf{A}$ ，矩阵 \mathbf{A} 为反 Hermitian 矩阵。这与实数阵的反对称矩阵类似。特征值为虚数，特征向量形成一个标准正交基。

如果 $\mathbf{A}^H \mathbf{A} = \mathbf{A} \mathbf{A}^H$ ，则称 \mathbf{A} 为标准阵。特征向量形成标准正交基。

如果 $\mathbf{A}^H \mathbf{A} = \mathbf{I}$ ，则称 \mathbf{A} 为酉矩阵。这类似于实数矩阵的正交阵。由此得 $\mathbf{A}^{-1} = \mathbf{A}^H$ 。 \mathbf{A} 的列形成标准正交基，行也一样。特征值一定为 1，特征向量形成标准正交基。

如果对每个 $\mathbf{x} \neq \mathbf{0}$ ，都有 $\mathbf{x}^H \mathbf{A} \mathbf{x} > 0$ ，则称 Hermitian 矩阵为正定的。所有特征值均为正数。

用同样的方式可以对较弱的条件 $\mathbf{x}^H \mathbf{A} \mathbf{x} \geq 0$ 定义半正定矩阵，特征值均为非负。

对于某个整数 p ，如果 $\mathbf{A}^p = \mathbf{0}$ ，则称矩阵 \mathbf{A} 为幂零矩阵。如果 $\mathbf{A}^2 = \mathbf{A}$ ，则称矩阵 \mathbf{A} 为幂等矩阵。

如果存在相似变换 \mathbf{C} ，使得 $\mathbf{C}^{-1} \mathbf{A} \mathbf{C}$ 为对角阵，则称 \mathbf{A} 是对角化的。 \mathbf{A} 可对角化当且仅当 \mathbf{A} 有 n 个线性无关的特征向量。

B.5 特殊矩阵

所有元素均为零的矩阵称为零矩阵。所有元素均为 1 的矩阵称为 1 矩阵。单位矩阵主对角线上元素均为 1，其他元素均为零。随机矩阵的元素都是随机的。

Givens 旋转是具有如下形式的矩阵：

与单位阵的区别仅在 $(i, i), (i, j), (j, i)$ 和 (j, j) 四处。Givens 旋转是正交的。

$$\begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & \cos \theta & \sin \theta & \\ & & & \ddots & \\ & -\sin \theta & \cos \theta & & \\ & & & \ddots & \\ & & & & 1 \end{pmatrix}$$

Householder 反射是由 $\mathbf{I} - 2\mathbf{w}^H \mathbf{w}$ 定义的矩阵，其中 $\mathbf{w}^H \mathbf{w} = 1$ 。这些矩阵是酉矩阵和 Hermitian 矩阵。

高斯变换矩阵有如下的形式：

$$\begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & \ddots & & \\ & & & 1 & \\ & & & \times & \ddots \\ & & & \times & \ddots \\ & & & \vdots & \ddots \\ & & & \times & & 1 \end{pmatrix}$$

其中 \times 代表非零元素。它仅在对角线下方的一列上与单位阵有区别。

置换矩阵与单位矩阵有相同的列，但是次序不同。每行每列都有一个准确的单位元素。

B.6 向量和矩阵的范数

前面已经介绍了向量 \mathbf{x} 的欧氏范数或2-范数。

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = \sqrt{\mathbf{x}^H \mathbf{x}}.$$

介绍最大范数也是十分有用的。

$$\|\mathbf{x}\|_\infty = \max_{1 \leq i \leq n} |x_i|.$$

另一个范数是1-范数。

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|.$$

所有这些都是更一般的 p -范数的特例。

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}.$$

范数常用来度量向量的大小或长度。

矩阵范数用下式来定义：

$$\|\mathbf{A}\| = \max_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|} = \max_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

可以得到下面的结论：

- \mathbf{A} 的1-范数是列和绝对值的最大值。

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

- \mathbf{A} 的2-范数或谱范数：

$$\|\mathbf{A}\|_2 = \sqrt{\rho(\mathbf{A}^H \mathbf{A})}$$

而 \mathbf{A} 的最大范数是行元素绝对值之和的最大值。

$$\|\mathbf{A}\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|.$$

另一个常用的矩阵范数是F-范数 $\|\mathbf{A}\|_F$ ，用下面的式子定义：

$$\|\mathbf{A}\|_F^2 = \sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2.$$

F-范数不能象另外三个矩阵范数那样由向量范数定义得到。

有下列不等式：

1) 对任何矩阵 A 和它所有的范数, 有 $\rho(A) \leq \|A\|$ 。

2) 如果 A 为 Hermitian 矩阵, 则 $\rho(A) = \|A\|_2$ 。

3) 如果 A 为酉矩阵, 则 $\|A\|_2 = 1$ 。

使用矩阵范数可以对矩阵中扰动的灵敏性进行估计和度量。

线性方程组 $Ax=b$ 的条件数定义为:

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\|$$

有如下关系:

$$\frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\Delta b\|}{\|b\|}$$

其中, Δb 是对右侧 b 的扰动, 而 Δx 是对解向量 x 的相应的扰动。注意到关系中既有向量范数又有矩阵范数。对矩阵 A 中的扰动也有类似的关系。

B.7 矩阵因式分解

1) **LU 因式分解或 LU 分解** $PA=LU$, 其中 P 为扰动矩阵, L 为一个对角线上有元素为 1 的下三角矩阵, 而 U 为一个上三角矩阵。

2) **Cholesky 因式分解** 对称、正定矩阵 A 可以因式分解为 $A=GG^T$, 这里 G 为下三角阵。

3) **QR 因式分解** $A=QR$, 其中 A 是 $m \times n$ 矩阵, Q 是一个 $m \times m$ 的正交矩阵, 而 R 是 $m \times m$ 的上三角矩阵。

4) 假设 A 有 n 个线性无关的特征向量, 则存在矩阵 C , 使得 $C^{-1}AC=D$ 为对角阵, 即 $A= CDC^{-1}$, 该条件是充分必要的。一个充分条件是所有的特征值均不同。

5) **舒尔分解** 对每个矩阵 A , 存在矩阵 U , 使得 $U^H A U = T$ 为上三角阵, 即 $A=UTU^H$ 。

6) 对于 Hermitian 矩阵 A , 存在一个酉矩阵 U , 使得 $U^H A U = D$ 为对角阵, 即 $A=UTU^H$ 。

7) **Murnaghan-Winters 定理** 对于所有的实数阵 A , 存在实数正交阵 U , 使得 $U^T A U = B$ 为实数分块三角阵, 这里对角线上的块为 2×2 阶或 1×1 阶。每个 2 阶块代表一个特征值的复数共轭对。

8) **Jordan 标准形** 对每一个方阵 A , 存在一个非奇异矩阵 S , 使得 $S^{-1}AS=J$, 其中 J 为块对角阵的形式:

如果块 J_k 为一阶, 则 $J_k = (\lambda_k)$ 。与对角线上的每一个块相对应的一个特征向量也称为 Jordan 框。如果 Jordan 框的数目为 p , 则矩阵 A 有 p 个线性无关的特征向量。

$$J = \begin{pmatrix} J_1 & & \\ & J_2 & \\ & & \ddots \\ & & & J_p \end{pmatrix} \quad J_k = \begin{pmatrix} \lambda_k & 1 & & \\ & \ddots & \ddots & \\ & & \ddots & 1 \\ & & & \lambda_k \end{pmatrix}$$

9) **奇异值分解** 每个 $m \times n$ 矩阵 A 都可分解成两个酉矩阵 U 和 V , 使得 $U^T A V = D$ 是一个 $m \times n$ 对角阵。其中, U 是一个 $m \times m$ 矩阵, V 是一个 $n \times n$ 矩阵, 而 D 的对角元素为 σ_k 。这些元素有序排列为 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq 0$, 其中, $p = \min(m, n)$ 。如果有其他的 σ_k , 则为零。 σ_k 的值称为 A 的奇异值。因此 $A=UDV^T$ 。

奇异值可用于定义 \mathbf{D} 的广义逆 \mathbf{D}^+ 。下面在 $m \times n$ 的情况给出的定义：

$$\mathbf{D} = \left[\begin{array}{ccc|ccc} \sigma_1 & & & & & \\ & \ddots & & & & \\ & & \sigma_p & & & \\ \hline & & & & & \\ & & & & & \\ & & & & & \\ 0 & & & & & 0 \end{array} \right] \quad \mathbf{D}^+ = \left[\begin{array}{ccc|ccc} \sigma_1^{-1} & & & & & \\ & \ddots & & & & \\ & & \sigma_p^{-1} & & & \\ \hline & & & & & \\ & & & & & \\ & & & & & \\ 0 & & & & & 0 \end{array} \right]$$

但也同样适用于 $m \times n$ 。如果 \mathbf{D} 为 $m \times n$ 矩阵，则 \mathbf{D}^+ 为 $n \times m$ 矩阵。 \mathbf{A} 的广义逆 \mathbf{A}^+ 的大小也是 $n \times m$ ，并且用奇异值分解定义为 $\mathbf{A}^+ = \mathbf{V} \mathbf{D}^+ \mathbf{U}^T$ 。